

PRÁTICA DE TRATAMENTO DE DADOS

EAB067 - Aprendizado de Máquina

Atualizado em: 16 de março de 2026

Iago Carvalho

Departamento de Ciências da Computação

Programa de Pós-Graduação em
Estatística Aplicada e Biometria



BANCO DE DADOS A SER UTILIZADO

Vamos utilizar o *Credit Card Fraud Detection*

- Banco de dados disponível no Kaggle
- <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud?select=creditcard.csv>

Ele contém compras realizadas com cartões de crédito em Setembro de 2013 por titulares de cartões europeus.

Este conjunto de dados apresenta transações que ocorreram em dois dias, onde temos 492 fraudes em 284.807 transações.

- O conjunto de dados é altamente desbalanceado, a classe positiva (fraudes) representa 0,172% de todas as transações.

CARACTERÍSTICAS DO BANCO DE DADOS

O banco de dados possui 31 colunas, sendo que a variável *Class* é a nossa variável a ser predita

- Esta é uma variável binária, onde 1 indica que houve fraude e 0 indica que não houve fraude

Existe uma variável que não é relevante aos dados e deve ser descartada

OBJETIVOS

1. Balancear o banco de dados
2. Remover, artificialmente, algumas variáveis do banco
3. Usar diferentes algoritmos de imputação para prever novamente o valor das variáveis
 - Média, Mediana, KNN, MICE, Aprendizado de máquina
4. Avaliar os algoritmos de imputação de acordo com MAE e RMSE

MAE: Ela mede a média da diferença absoluta entre os valores previstos pelo modelo e os valores observados

RMSE: É a raiz quadrada da média dos quadrados dos erros, onde o erro bruto é a diferença entre o valor previsto pelo modelo e o valor real

FÓRMULAS DO MAE E RMSE

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - p_i|$$

$$RMSE = \frac{1}{n} \sqrt{\sum_{i=1}^n (y_i - p_i)^2}$$

onde

- n é o número de amostras
- y_i é o valor observado para a amostra i p_i é o valor predito para a amostra i