

TIPOS DE MODELOS DE APRENDIZADO DE MÁQUINA

EAB067 - Aprendizado de Máquina

Atualizado em: 19 de março de 2026

Iago Carvalho

Departamento de Ciências da Computação

Programa de Pós-Graduação em
Estatística Aplicada e Biometria



TIPOS DE APRENDIZAGEM

Basicamente existem quatro tipos (ou variedades) de algoritmos de aprendizado

1. Aprendizado não supervisionado
2. Aprendizado supervisionado
3. Aprendizado semi-supervisionado
4. Aprendizado por reforço

Veremos os quatro tipos a seguir

- A maior diferença está na presença ou não de rótulos nas variáveis

ROTULAGEM DE DADOS

Para entender e diferenciar os quatro tipos, primeiro devemos definir o que é um **dado rotulado**

Um rótulo (ou *label*) é algo que, de alguma forma, identifica o dado

- Funciona como se fosse uma classe

Dados rotulados		Dados rotulados		Dados não rotulados	
					
Cachorro	Cachorro	8.16 kg	6.35 kg		
					
Gato	Gato	5.44 kg	4.08 kg		

Rotular dados é uma tarefa custosa

- Tanto em termos de tempo quanto de dinheiro
- Em geral, envolve esforço humano
 - Muitas vezes, de especialistas no conjunto de dados em questão

Dados sem rótulos são baratos e mais simples de se obter

- Na verdade, rotular corretamente dados é uma das tarefas mais caras existentes no desenvolvimento de modelos de ML

APRENDIZADO NÃO-SUPERVISIONADO

Um modelo de aprendizado de máquina **não-supervisionado** é aquele que utiliza dados **sem rótulos**

Algoritmos de aprendizado de máquina não-supervisionados tem como objetivo explorar um conjunto de dados

As principais tarefas não-supervisionadas são

- Clusterização
- Associação
- Redução de dimensionalidade

Um algoritmo de **clusterização** tenta agrupar determinadas entradas em **grupos**

- Agrupamento definido por similaridade das variáveis de entrada
- Número de grupos pode ser fixo ou dinâmico

Existem diversos algoritmos de clusterização


- K-Means
- DBSCAN
- *Gaussian Mixture Models* (GMM)

MODELOS NÃO-SUPERVISIONADOS - K-MEANS

Computa *clusters* de acordo com a distância entre as variáveis

○ Euclidiana, edição, Mahalanobis, Manhattan, Chebyshev, ...

Não possui nenhum hiperparâmetro, mas requer dados normalizados ou padronizados





MODELOS NÃO-SUPERVISIONADOS - DBSCAN

Identifica áreas densamente *povoadas* no espaço de *features*

○ Muito útil para identificar *outliers*

Utiliza dois hiperparâmetros

1. ϵ : raio a ser verificado
2. *min_samples*: número de amostras mínimo



MODELOS NÃO-SUPERVISIONADOS - ASSOCIAÇÃO

Associações são co-ocorrências entre dados

- Útil em aplicações reais para descobrir o que *casa* com o quê
- Principais algoritmos: Apriori, Eclat, FPGrowth, AIS

Muito útil em sistemas de recomendação e sistemas médicos

- Se alguém assistiu o filme A, provavelmente também gostará do filme B
- Se o paciente tem sintomas X e Y, provavelmente ele tem uma doença Z

Algoritmos de associação funcionam bem com variáveis categóricas

- Pode ser necessário categorizar variáveis contínuas

MODELOS NÃO-SUPERVISIONADOS - DIMENSIONALIDADE

Algoritmos de redução de dimensionalidade tentam transformar dados de muitas dimensões em dados de menor dimensão

- Tentam manter informações essenciais e reduzir ruído

No geral, funcionam como técnicas de *feature extraction* ou *selection*

- Criam novas variáveis como combinações das variáveis originais ou eliminam algumas variáveis pré-existentes

Diversos algoritmos existem

- Análise de componentes principais (PCA)
- Métodos *wrappers*
 - *Forward selection, backward selection*


MODELOS NÃO-SUPERVISIONADOS - PCA

Um algoritmo PCA cria novas variáveis como combinações lineares das variáveis existentes

- Muito útil para tratar variáveis co-lineares e reduzir o ruído

Ele tenta encontrar os chamados *componentes principais*

- Combinações lineares de variáveis que maximizam a variância dos dados originais



MODELOS NÃO-SUPERVISIONADOS - WRAPPERS

Criam diversos modelos, incluindo (ou deletando) variável por variável e avaliando as métricas de qualidade do aprendizado

Forward selection

1. Inicia com um modelo com $p = 0$ variáveis (somente o intercepto)
2. Testa modelos de $p + 1$ variáveis
3. Inclui aquela de maior correlação ou que resulta na maior melhora do modelo
4. Faz $p = p + 1$ e retorna ao passo 2

Backward selection

1. Inicia com um modelo com p variáveis (todas as possíveis)
2. Testa modelos de $p - 1$ variáveis
3. Remove a variável menos significativa (maior p -valor)
4. Faz $p = p - 1$ e retorna ao passo 2

APRENDIZADO SUPERVISIONADO

Um modelo de aprendizado de máquina **supervisionado** é aquele que utiliza dados **rotulados**

No geral, quando você pensa em aprendizado de máquina, você costuma pensar em exemplos de modelos supervisionados

- Redes neurais, árvores de decisão, florestas aleatórias, SVM, XGBoost, ...

As principais tarefas supervisionadas são

- Regressão (inferência)
- Classificação

O modelo mais clássico de aprendizado de máquina

Consistem de uma camada de entrada, uma camada de saída, e uma ou mais camadas ocultas


- Os nós (neurônios) se conectam com a camada anterior e posterior
- Uma rede neural tenta emular as conexões sinápticas do cérebro humano

Redes neurais utilizam dados rotulados para ajustar os pesos das conexões neuronais

- Algoritmo *backpropagation*

MODELOS SUPERVISIONADOS - REDES NEURAIS

Existem diversas implementações de redes neurais, cada um com um objetivo diferente



CART - Classification and Regression Trees


São estruturas de árvore que tomam decisões sequenciais sobre as variáveis do modelo

- A cada decisão, os dados são divididos em subconjuntos menores
- Ao atingir o fim da árvore, temos uma classificação (ou regressão)

Produzem modelos altamente explicáveis, são capazes de lidar muito bem com *outliers* e podem utilizar tanto variáveis lineares como categóricas



MODELOS SUPERVISIONADOS - ÁRVORES DE CLASSIFICAÇÃO

Podem ser utilizadas para classificação



MODELOS SUPERVISIONADOS - ÁRVORES DE CLASSIFICAÇÃO

Também podem ser utilizadas para regressão



Um conjunto de CARTs semi-aleatórias independentes

- Cada CART avalia um diferente sub-conjunto de variáveis em diferentes ordens
- Se for para classificação, o resultado é a **moda**
- Se for para regressão, o resultado é a **média**

Considerado um *ensemble*

- Difícil de otimizar seus hiperparâmetros
- Computacionalmente caro pois possui muitas CARTs
 - Em geral, possui entre 500 e 1000 CARTs


eXtreme Gradient Boosting

- Um algoritmo de *boosting* baseado em CARTs semi-aleatórios
- Também é difícil de otimizar seus hiperparâmetros

Ao invés de obter o resultado médio (ou moda) como florestas aleatórias, utiliza a saída de um CART como entrada para outro

- Ao fim do último CART, temos a inferência final do algoritmo

MODELOS SUPERVISIONADOS - XGBOOST



APRENDIZADO SEMI-SUPERVISIONADO E POR REFORÇO

São algoritmos que possuem alguns dados com rótulos e outros não

Operam em duas fases

1. Fazer o aprendizado nos dados rotulados
2. Buscam generalizações nos dados não rotulados

Cada fase utiliza algoritmos clássicos para aprendizado supervisionado ou não-supervisionado

São modelos de aprendizado de máquina que aprendem interagindo com o ambiente

- Reforço positivo ou negativo
- São considerados **agentes**

Não precisam de dados rotulados

- Entretanto, podem utilizar de *feedbacks* humanos
- Eles tendem a melhorar com o tempo

CONCEITOS DE APRENDIZADO POR REFORÇO

- O agente é o algoritmo de ML (ou o sistema autônomo)
- O ambiente é o espaço adaptativo do problema com atributos como variáveis, valores limite, regras e ações válidas
- A ação é uma etapa que o agente de RL executa para navegar pelo ambiente
- O estado é o ambiente em um determinado momento
- A recompensa é o valor positivo, negativo ou zero, em outras palavras, a recompensa ou punição, por realizar uma ação
- A recompensa cumulativa é a soma de todas as recompensas ou o valor final

APRENDIZADO POR REFORÇO BASEADOS EM MODELOS

Normalmente é usado quando os ambientes são bem definidos e imutáveis e onde o teste do ambiente no mundo real é difícil

O atendente primeiro cria uma representação interna (modelo) do ambiente. Ele usa esse processo para criar esse modelo:

1. Ele realiza ações dentro do ambiente e observa o novo estado e o valor da recompensa
2. Ele associa a transição do estado de ação ao valor da recompensa.

Quando o modelo é concluído, o atendente simula sequências de ação com base na probabilidade de recompensas cumulativas ideais

Em seguida, atribui ainda mais valores às próprias sequências de ação. Assim, o atendente desenvolve diferentes estratégias dentro do ambiente para atingir o objetivo final desejado

APRENDIZADO POR REFORÇO BASEADOS EM MODELOS

Um ótimo exemplo de um algoritmo de aprendizado por reforço baseado em modelo é um robô aspirador



APRENDIZADO POR REFORÇO SEM MODELO

Utilizado quando o ambiente é grande, complexo e não é facilmente descritível

- Também é utilizado quando o ambiente é desconhecido, está mudando e os testes baseados no ambiente não apresentam desvantagens significativas

O atendente não cria um modelo interno do ambiente e de sua dinâmica

Em vez disso, ele usa uma abordagem de tentativa e erro dentro do ambiente

- Ele pontua e anota pares de ações estatais e sequências de pares de ações estatais para desenvolver uma política

APRENDIZADO POR REFORÇO SEM MODELO

Utilizado quando o ambiente é grande, complexo e não é facilmente descritível

- Também é utilizado quando o ambiente é desconhecido, está mudando e os testes baseados no ambiente não apresentam desvantagens significativas

O atendente não cria um modelo interno do ambiente e de sua dinâmica

Em vez disso, ele usa uma abordagem de tentativa e erro dentro do ambiente

- Ele pontua e anota pares de ações estatais e sequências de pares de ações estatais para desenvolver uma política

APRENDIZADO POR REFORÇO SEM MODELO

Um ótimo exemplo de um algoritmo de aprendizado por reforço sem modelo é um carro autônomo

