

TRATAMENTO DE DADOS

EAB067 - Aprendizado de Máquina

Atualizado em: 16 de março de 2026

Iago Carvalho

Departamento de Ciências da Computação

Programa de Pós-Graduação em
Estatística Aplicada e Biometria



Tratamento de dados, também conhecido como limpeza de dados ou *data cleansing*, é o processo de identificar e corrigir erros e inconsistências em conjuntos de dados brutos

Seu objetivo é garantir que dados sejam precisos, completos, consistentes e utilizáveis para análise ou tomada de decisão

- Isto implica em melhor qualidade de modelos de aprendizado de máquina

Dados ruins levam a modelos, análises e decisões ruins

- Não importa o quão bom sejam seus modelos e visualizações se eles não utilizam dados de qualidade

Existem diversos tipos de problemas em dados, como veremos a seguir

PRINCIPAIS ERROS EM DADOS

DADOS FALTANTES

Dados faltantes (ou ausentes) em colunas utilizadas em seu modelo

	col1	col2	col3	col4	col5			col1	col2	col3	col4	col5	
0	2	5.0	3.0	6	NaN	mean()		0	2.0	5.0	3.0	6.0	7.0
1	9	NaN	9.0	0	7.0			1	9.0	11.0	9.0	0.0	7.0
2	19	17.0	NaN	9	NaN			2	19.0	17.0	6.0	9.0	7.0

DADOS DUPLICADOS

Um mesmo dado é utilizado como entrada mais de uma vez

	id	first_name	last_name	email
▶	1	Carine	Schmitt	carine.schmitt@verizon.net
	4	Janine	Labrune	janine.labrune@aol.com
	6	Janine	Labrune	janine.labrune@aol.com
	2	Jean	King	jean.king@me.com
	12	Jean	King	jean.king@me.com
	5	Jonas	Bergulfsen	jonas.bergulfsen@mac.com
	10	Julie	Murphy	julie.murphy@yahoo.com
	11	Kwai	Lee	kwai.lee@google.com
	3	Peter	Ferguson	peter.ferguson@google.com
	9	Roland	Keitel	roland.keitel@yahoo.com
	14	Roland	Keitel	roland.keitel@yahoo.com
	7	Susan	Nelson	susan.nelson@comcast.net
	13	Susan	Nelson	susan.nelson@comcast.net
	8	Zbyszek	Piestrzeniewicz	zbyszek.piestrzeniewicz@att.net


FORMATOS INCONSISTENTES

Um dado tem formao inconsistente quando não existe um padrão ou notação padronizada para representar uma categoria

39	Male			
40	Male			
41	Male		Row Labels  Count of Gender	
42	Male		M	15
43	M		Male	42
44	M		Man	8
45	M		Grand Total	65
46	M			
47	M			

OUTLIERS


Outliers normalmente não são uma boa representação de seus dados e introduzem ruídos no modelo



OUTLIERS E RUÍDOS

Deve-se separar um *outlier* de um ruído (noise)

- Um ótimo algoritmo para isso é o DBSCAN



Um *typo* é um erro ou variação na escrita de palavras



TIPOS DE DADOS INCORRETOS

O tipo da variável (inteira, binária, *string*, etc) tem que ser consistente e respeitado

Datas	Datas
26/11/2022	26 de novembro de 2022
14/04/2023	14 de abril de 2023
27/04/2024	27 de abril de 2024
10/12/2022	10 de dezembro de 2022
18/12/2024	18 de dezembro de 2024
28/02/2024	28 de fevereiro de 2024
08/03/2022	08 de março de 2022
29/07/2023	29 de julho de 2023
16/12/2022	16 de dezembro de 2022
12/04/2021	12 de abril de 2021

TÉCNICAS DE LIMPEZA DE DADOS

Para iniciar a limpeza de dados devemos inicialmente **estudar** o banco de dados que estamos trabalhando

- Verificar dados duplicados, faltantes, *outliers*, inconsistências, etc

Uma boa maneira de fazermos isso é com uma análise exploratória de dados

- Diferentes implementações em diferentes linguagens de programação
- *ydata-profiling* no Python

Se você tem dados ausentes, existem algumas opções de tratamento

1. Apagar as linhas com dados faltantes
2. Fazer a imputação de dados
3. Criar uma variável categórica nova (dados completos, dados incompletos)

Existem diversos algoritmos de imputação de dados

- Veremos no decorrer desta aula

ARRUMANDO A FORMATAÇÃO DOS DADOS

Todos os dados tem que estar consistentes. Uma boa estratégia consiste em

1. Converter todos os caracteres para minúsculo
2. Remover espaços extras
3. Trocar entradas inconsistentes por entradas padrões
 - “N/A”, “na”, ou “none” por “null”

Nesta etapa também é interessante checar os tipos de dados e garantir sua consistência

Outliers podem afetar drasticamente sua análise

- Forte influência na média
- Visualizações "tortas"
- Inserção de ruídos em modelos estatísticos e de ML

As vezes, um *outlier* é uma leitura errada

- Outras vezes, ele é um dado valioso sobre algo que realmente pode ocorrer com seus dados

Em tarefas de classificação, pode acontecer de um banco de dados prover números extremamente diferentes de dados de cada classe

Para prevenir que o algoritmo tenha um *overfitting* na classe predominante, deve-se balancear os dados

- Remover dados da classe dominante
- Incluir mais dados das classes minoritárias

Depois de tratar todos os dados, você deve então fazer uma segunda análise exploratória

- O objetivo é verificar se tudo realmente foi corrigido

Caso ainda existam erros ou inconsistências, deve-se trata-los antes de dar continuidade ao trabalho

IMPUTAÇÃO DE DADOS

Dados faltantes podem ser classificados em três categorias¹

- Missing Completely at Random (MCAR)
- Missing at random (MAR)
- Missing not at random (MNAR)

É importante entenderos cada categoria para saber como tratar os dados faltantes de maneira efetiva

¹Rubin, D. B. 1976. "Inference and Missing Data." Biometrika 63 (3): 581–90.

MISSING COMPLETELY AT RANDOM (MCAR)

É quando a probabilidade dos dados estarem ausentes é independente de qualquer observação no banco de dados

- Não existe conseguimos uma correlação entre as classes que possuem dados ausentes e as classes que não possuem dados ausentes

Em outras palavras, não é possível identificar uma relação entre as amostras sem preenchimento e aquelas completamente preenchidas

MISSING AT RANDOM (MAR)

É quando a probabilidade dos dados estarem ausentes é dependente de outros dados

- Existe uma correlação entre o dado faltante e um dado observado
- O dado faltante é dependente dos dados observados

Um exemplo disso são formulários respondidos por homens e mulheres

- Pode ser que o homem (ou a mulher) tenham a tendência a não responder uma questão específica

MISSING NOT AT RANDOM (MNAR)

A probabilidade é que os valores faltantes dependam dos dados observados e dos dados não observados




- O dado faltante é relacionado com o próprio dado em si

Este modelo é extremamente difícil de identificar e tratar

Um exemplo pode ser em um questionário de renda

- Pessoas de alta renda tendem a não querer compartilhar quanto ganham com outros

MCAR, MAR E MNAR



MCAR, MAR E MNAR

MCAR: Aleatório absoluto

- Erro de digitação aleatório
 - Teste MCAR de Little
 - Remoção dos dados faltantes ou uso de imputação
-

MAR: A causa está visível em outra coluna

- Dados de saúde faltantes para crianças
 - Correlação entre dados faltantes e outras variáveis
 - Necessário realizar imputação de dados
-

MNAR: A causa está oculta na própria coluna

- Quem tem medo não responde à pesquisa sobre medo
- Difícil de detectar
- Difícil de arrumar; Necessário uma modelagem mais complexa

COMO TRATAR DADOS FALTANTES

1. Remover os dados faltantes
2. Não fazer nada
3. Utilizar média, moda ou mediana
4. *Last Observation Carried Forward* (LOCF)
5. KNN
6. Aprendizado de máquina e *deep learning*
7. *Chained Equations*
8. Deep Learning
9. LLM

REMOVER OS DADOS FALTANTES

Se uma linha tem um dado faltante, então ela deve ser removida

Esta abordagem resolve o problema

- Entretanto, pode-se perder muitos dados de entrada

Útil quando existe um número inexpressivo de dados faltantes

- Baixo percentual em relação aos dados totais

NÃO FAZER NADA

Dependendo do modelo de ML que você esteja utilizando, esta pode ser uma alternativa

Modelos como o XGBoost e o LightGBM podem trabalhar com dados faltantes

Outros, como o Random Forest e a regressão linear são incapazes de lidar com os dados faltantes

Substituir os valores faltantes pela média, moda ou mediana da coluna

Funciona bem com dados numéricos, mas não funciona com dados categóricos

Não leva em consideração a correlação dos dados faltantes com demais variáveis do modelo

Muito útil em séries temporais

Substitui o dado faltante pela última observação disponível daquele dado

Método simples, mas pode melhorar

- Interpolação linear entre pontos
- Modelos mistos para medidas repetidas

O algoritmo KNN é tradicionalmente utilizado para imputar dados

O KNN leva em consideração a correlação dos dados faltantes com as demais variáveis do modelo

Se houver *outliers*, o KNN pode produzir resultados ruins

Além disso, ele pode demorar a executar

Algoritmos podem *aprender* os dados e gerar a imputação

Podem ser utilizados algoritmos de regressão simples, regressão múltipla, random forest ou redes neurais

Levam a bons resultados, mas necessitam de grande carga de trabalho

- Tanto computacional como humano

Algoritmo iterativo que modela dados faltantes em função das demais variáveis do modelo²

Realiza imputação múltipla e iterativa

Pode ser utilizado em qualquer tipo de variável

- Contínuas, inteiras, binárias ou categóricas

²Van Buuren, Stef, and Karin Groothuis-Oudshoorn. "mice: Multivariate imputation by chained equations in R." Journal of statistical software 45 (2011): 1-67.

Algoritmos de LLM também podem ser utilizados para imputar dados

Todo o banco de dados é carregado para o algoritmo LLM e ele tenta gerar os tokens (valores de variáveis) mais prováveis em cada coluna faltante


Quanto melhor o banco de dados for descrito no *prompt*, melhores serão os resultados

BALANCEAMENTO DE DADOS

DADOS DESBALANCEADOS

Em um banco de dados desbalanceado, as classes de um conjunto de dados não estão representadas de forma equilibrada

- Na prática, isso significa que uma classe (majoritária) possui significativamente mais exemplos do que a outra (minoritária)



Modelos de classificação treinados com dados desbalanceados tendem a ser viesados, favorecendo a classe majoritária

Isso acontece porque o algoritmo busca minimizar o erro total, o que pode levar a uma acurácia enganosa

- O modelo pode prever sempre a classe mais frequente e ainda assim ter uma grande taxa de acerto
- Entretanto, ele falha justamente no que é mais importante
 - Detectar a entrada mais *rara* do banco de dados, como uma doença, fraude ou ataque

COMO IDENTIFICAR DESBALANCEAMENTO DE DADOS

A maneira mais simples é na análise exploratória de dados com um histograma (como na figura anterior)

Outra maneira, após o aprendizado, é através da matriz de confusão

- Se a acurácia for alta, mas a precisão e o recall da classe minoritária forem baixos, você tem um problema de desbalanceamento.

Ajuste de pesos: Você pode configurar o algoritmo para dar *mais importância* (maior peso) aos erros cometidos na classe minoritária durante o treinamento

Reamostragem: Técnicas de reamostragem podem ser utilizadas para modificar o número de entradas do seu banco de dados

- Undersampling (subamostragem)
- Oversampling (superamostragem, algoritmo SMOTE)
- Combinação de ambas as abordagens

COMO RESOLVER O PROBLEMA DE BALANCEAMENTO

