

APRENDIZADO NÃO-SUPERVISIONADO

EAB067 - Aprendizado de Máquina

Atualizado em: 7 de abril de 2026

Iago Carvalho

Departamento de Ciências da Computação

Programa de Pós-Graduação em
Estatística Aplicada e Biometria



Como vimos nas aulas anteriores, algoritmos de aprendizado de máquina não-supervisionados utilizam dados **não rotulados**

Além disso, também vimos que suas principais aplicações são

- Clusterização
- Associação
- **Redução de dimensionalidade**

Hoje vamos discutir principalmente métodos de redução de dimensionalidade

REDUÇÃO DE DIMENSIONALIDADE

MALDIÇÃO DA DIMENSIONALIDADE

A maldição da dimensionalidade refere-se a vários fenômenos que surgem ao analisar e organizar dados em espaços de alta dimensionalidade (frequentemente centenas de dimensões) e que não ocorrem em ambientes de baixa dimensionalidade

À medida que as dimensões aumentam, os dados tornam-se esparsos

- Dificuldade em identificar padrões
- Distâncias entre pontos tornam-se indistinguíveis
- Maior risco de *overfitting* e introdução de ruído

Além disso, também há um grande custo computacional para processar dados de alta dimensionalidade

REDUÇÃO DE DIMENSIONALIDADE

Reduzir a dimensionalidade de um conjunto de dados consiste em reduzir seu número de variáveis de entrada (*features*)

- Tentamos ainda preservar informações essenciais dos dados
1. **Desempenho aprimorado do modelo:** Menos ruído nos dados melhora a precisão do modelo preditivo.
 2. **Treinamento mais rápido:** O volume de dados reduzido diminui significativamente o custo computacional.
 3. **Melhor visualização:** Dados de alta dimensionalidade (por exemplo, milhares de características) podem ser projetados em 2D ou 3D para plotagem.
 4. **Redução do *overfitting*:** Um número menor de variáveis reduz o risco de modelagem de ruído.

Temos duas principais classes para redução de dimensionalidade

1. *Feature extraction*

- Novas variáveis são criadas com base nas anteriores

2. *Feature selection*

- Uma ou mais variáveis são selecionadas
- As outras são removidas

Elas podem ser utilizadas separadas ou em conjunto

- Primeiro, realiza-se *feature selection*
- Depois, é aplicado o *feature extraction*

FEATURE EXTRACTION

FEATURE EXTRACTION

Feature extraction, também conhecido como *feature projection*, é o processo de transformar um conjunto de dados de um espaço com muitas dimensões em um com um número menor de dimensões

A transformação dos dados pode ser linear ou não-linear

Linear

- **Análise de componentes principais (PCA)**
- Análise Discriminante Linear (LDA)
 - Algoritmo supervisionado

Não-linear

- Kernel PCA
- Análise Discriminantes Generalizada (GDA)
- T-distributed Stochastic Neighbor Embedding (t-SNE)

O PCA tem suas origens no início do século XX quando pesquisadores tentavam representar variáveis complexas utilizando índices sintéticos

- Estes índices deveriam capturar a maior parte da informação original


A partir daí, o PCA se desenvolveu como uma transformação linear ortogonal que projeta os dados em um novo sistema de coordenadas

- A maior variância possível é capturada no primeiro eixo (o primeiro componente principal)
- A segunda maior variância é capturada no segundo eixo (o segundo componente principal)

ANÁLISE DE COMPONENTES PRINCIPAIS

Geometricamente, se imaginarmos um conjunto de dados como uma nuvem de pontos em um espaço p -dimensional, a PCA busca identificar os eixos principais dessa "elipsoide" de dados

- O primeiro componente principal aponta na direção de maior alongamento da nuvem
- O segundo componente deve ser ortogonal ao primeiro e apontar na direção da maior variabilidade remanescente



A PCA é usada para pré-processamento de dados para uso com algoritmos de aprendizado de máquina

Ao projetar um conjunto de dados de alta dimensionalidade em um espaço de características menor, a PCA também minimiza, ou elimina completamente, problemas comuns como multicolinearidade e *overffiting*

Para entendermos a PCA, precisamos de uma breve revisão de conceitos de álgebra linear e operações matriciais

- Matriz de covariância
- Autovalores
- Autovetores

MATRIZ DE COVARIÂNCIA

Uma **matriz de covariância** é uma matriz simétrica que sumariza a covariância entre N variáveis

$$\text{variância}(x) = \frac{\sum_{i=0}^n (x_i - \bar{x})^2}{n - 1}$$

$$\text{covariancia}(x, y) = \frac{\sum_{i=0}^n [(x_i - \bar{x}) \cdot (y_i - \bar{y})]}{n - 1}$$

onde

- x_i e y_i são as diferentes observações das variáveis x e y
- $\bar{x}$ e $\bar{y}$ são as médias das variáveis x e y
- n é o número de amostras (linhas) do conjunto de dados

MATRIZ DE COVARIÂNCIAS

$$\begin{bmatrix} \text{var}(x_1) & \dots & \text{cov}(x_n, x_1) \\ \vdots & \ddots & \vdots \\ \text{cov}(x_1, x_n) & \dots & \text{var}(x_n) \end{bmatrix}$$

Vale a pena lembrar que ela é simétrica, ou seja

○ $\text{cov}(x_a, x_b) = \text{cov}(x_b, x_a)$

AUTOVALORES E AUTOVETORES

Os autovetores fornecem a direção da variância no gráfico de dispersão

Já os autovalores representam o coeficiente dos autovetores

- Quanto maior o autovalor associado a um autovetor, maior é sua importância

Os componentes principais de um PCA são os autovetores com maiores coeficientes associados

FUNCIONAMENTO DA PCA

A PCA pode ser sumarizada em alguns passos simples

1. Padronizar o intervalo de variáveis
2. Computar a matriz de covariância para identificar correlações
3. Computar os autovalores e autovetores da matriz de covariância
 - Resolução de determinantes da matriz de covariância
4. Selecionar os componentes principais desejados
5. Projetar os dados iniciais nos componentes principais escolhidos
 - $Y = XW$
 - Y é o conjunto de dados resultante
 - X é o conjunto de dados padronizado (passo 1)
 - W é a matriz composta pelos autovetores selecionados

FEATURE SELECTION

FEATURE SELECTION

Feature selection é o processo de escolher as variáveis mais relevantes de um conjunto de dados para usar na construção e no treinamento de um modelo de aprendizado de máquina

Ao reduzir o espaço de características a um subconjunto selecionado, a seleção de características melhora o desempenho do modelo de IA, diminuindo suas demandas computacionais

Todas as variáveis



Feature selection



Variáveis finais



BENEFÍCIOS DO *FEATURE SELECTION*

1. Melhor performance do modelo
 - Remoção de variáveis não importantes pode ajudar o modelo
2. Redução do *overffiting*
 - Redução do ruído e sobreajuste aos dados originais
3. Menor custo computacional e menor tempo de treinamento
 - É mais fácil treinar um conjunto de dados menor
4. Maior interpretabilidade do modelo
 - Menos variáveis, mais fácil de entender

PRINCIPAIS MÉTODOS DE *FEATURE SELECTION*

- Métodos de filtragem
- Métodos *wrapper*
- Métodos incorporados

Todos estes métodos são baseados em aprendizado supervisionado

- Deste modo, estudaremos métodos de *feature selection* nas próximas aulas