

TREINAMENTO DE MODELOS DE APRENDIZADO SUPERVISIONADO

EAB067 - Aprendizado de Máquina

Atualizado em: 12 de maio de 2026

Iago Carvalho

Departamento de Ciências da Computação

Programa de Pós-Graduação em
Estatística Aplicada e Biometria



Como vimos nas aulas anteriores, algoritmos de aprendizado de máquina supervisionados utilizam dados **rotulados**

Além disso, também vimos que suas principais aplicações e os principais algoritmos de aprendizado

Hoje veremos como treinar estes modelos de aprendizado supervisionado

FUNDAMENTOS

Definição Formal

Dado um conjunto de treinamento $\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^N$, gerado i.i.d. por uma distribuição de probabilidade conjunta desconhecida $P(x, y)$, o objetivo é induzir uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$ a partir de um espaço de hipóteses $\mathcal{H}$.

Componentes:

- $x \in \mathbb{R}^d$: Vetor de características (Features).
- $y \in \mathcal{Y}$: Variável alvo (Target).
- Se $\mathcal{Y} = \mathbb{R} \implies$ **Regressão**.
- Se $\mathcal{Y} = \{c_1, c_2, \dots, c_k\} \implies$ **Classificação**

RISCO ESPERADO VS. RISCO EMPÍRICO

A qualidade de f é medida por uma função de perda $L(y, f(x))$

- y é o dado verdadeiro
- $f(x)$ é o valor estimado

O **Risco Esperado** (Erro de Generalização) é a esperança da perda em toda a distribuição P

$$R(f) = \mathbb{E}_{(x,y) \sim P}[L(y, f(x))]$$

Como P é desconhecida, o problema de otimização exato é intratável

Recorremos à **Minimização do Risco Empírico (ERM)**

$$\hat{R}(f) = \frac{1}{N} \sum_{i=1}^N L(y^{(i)}, f(x^{(i)}))$$

MEDIDAS DE PERDA: VIÉS E VARIÂNCIA

O **viés** mede o quão distance, em média, as previsões de um modelo estão dos dados reais

- Modelos com alto viés tendem a fazer suposições fortes sobre a forma dos dados e causam *underfitting*
- Um modelo excessivamente simplista tende a ter alto viés e baixa variância
 - Um modelo como esse tende a ter altos erros de treinamento e altos erros de previsão.

A **variância** mede o quanto as previsões de um modelo mudam com diferentes conjuntos de dados de treinamento

- Modelos com alta variância são sensíveis a ruídos nos dados de treinamento e podem causar *overfitting*
- Um modelo com arquitetura complexa e mais parâmetros tende a ter alta variância e baixo viés


O DILEMA VIÉS-VARIÂNCIA (BIAS-VARIANCE TRADEOFF)

Para a perda quadrática, o erro esperado de um modelo $\hat{f}(x)$ em um ponto não visto x pode ser decomposto em três componentes fundamentais:

$$\mathbb{E} \left[(y - \hat{f}(x))^2 \right] = \text{Viés}(\hat{f}(x))^2 + \text{Var}(\hat{f}(x)) + \sigma^2$$


- **Viés (Bias):** Erro introduzido por aproximar um problema complexo com um modelo simples.
- **Variância (Variance):** Sensibilidade do modelo a flutuações no conjunto de treinamento.
- **Ruído Irreduzível (σ^2):** Variância inerente aos dados. Limite inferior fundamental de qualquer modelo.

VIÉS E VARIÂNCIA




VIÉS E VARIÂNCIA


Underfit



Overfit



VIÉS E VARIÂNCIA




EXEMPLO DE VIÉS-VARIÂNCIA

Vamos exemplificar este conceito utilizando modelos de regressão

Assuma que o erro de um modelo de regressão será medido como o erro médio quadrático (MSE)

$$MSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


Vamos construir um modelo de regressão para inferir y a partir de x



VIÉS-VARIÂNCIA: REGRESSÃO LINEAR

Assuma um modelo de regressão linear simples $\hat{y} = \beta_0 + \beta_1 x$


- O viés é alto: o modelo não consegue capturar o padrão não linear nos dados
- A variância é baixa: o modelo é estável e não muda muito com diferentes conjuntos de dados
- $MSE = 0,2929$: Este valor é relativamente alto



VIÉS-VARIÂNCIA: REGRESSÃO LINEAR

Agora assuma $\hat{y} = \beta_0 + \beta_1x + \beta_2x^2 + \beta_3x^3 + \beta_4x^4$


- O viés é moderado: o modelo consegue representar a função verdadeira de forma satisfatória
- A variância é moderada: o modelo não reage de forma exagerada a pequenas flutuações nos dados
- $MSE = 0,0714$: melhor que a regressão anterior



VIÉS-VARIÂNCIA: REGRESSÃO LINEAR

Agora assuma $\hat{y} = \beta_0 + \sum_{i=1}^{25} \beta_i x^i$

- O viés é baixo: É flexível o suficiente para seguir os dados originais
- A variância é alta: Reage fortemente ao ruído e mudaria significativamente com uma nova amostra de dados
- $MSE = 0,059$: Memorizou demais o padrão dos dados de treinamento



A IMPORTÂNCIA DO AJUSTE DE MODELOS

Para obtermos bons modelos é de extrema importância treinarmos efetivamente nossos modelos de aprendizado de máquina

A diferença entre a performance de treino e a de teste define a capacidade de generalização do modelo

Overfitting

O modelo captura o ruído dos dados de treino como se fossem padrões reais. Baixo erro de treino, alto erro de teste.

Underfitting

O modelo é muito simples para capturar a estrutura subjacente dos dados. Alto erro em ambos os conjuntos.

Tradicionalmente, dividimos os dados em três partes

1. **Treino** (60%-80%): Ajuste dos parâmetros
 - Dados usados para ensinar o modelo, onde ele aprende os padrões
2. **Validação** (10%-20%): Seleção de hiperparâmetros
 - Além disso, também é usado para monitorar o desempenho, ajustar hiperparâmetros e prevenir *overfitting*
3. **Teste** (10%-20%): Estimativa final de performance
 - Dados independentes e nunca vistos antes pelo modelo, usados para avaliar a precisão final
 - Mede a capacidade de generalização do modelo

TREINO

Os dados de treino são divididos em K partições (*folds*) iguais


Em cada uma das K iterações

1. Um *fold* é retido para teste
2. O restante dos *folds* são usados para treino
3. O modelo é avaliado no fold retido
4. A performance final é a média aritmética das K pontuações

PORQUÊ USAR VALIDAÇÃO CRUZADA?

- Todos os dados são utilizados para treino e teste
- Reduz a variância da estimativa de erro comparado a um único *fold*
- Detecta se o modelo é sensível a flutuações específicas nos dados

K-FOLD CROSS-VALIDATION




class são os diferentes *labels*;

group são informações sobre um mesmo indivíduo

SHUFFLE SPLIT

Dados são inicialmente embaralhados

- Então, executa-se o *K-fold cross validation* normalmente



REPEATED CROSS VALIDATION

Executa o K-Fold n vezes, com diferentes embaralhamentos em cada repetição


- Diferentes sementes para o gerador de números pseudo-aleatórios

Porquê repetir?

Reduz a variância da estimativa final do erro, fornecendo um intervalo de confiança mais robusto para a média das *scores*

LEAVE-ONE-OUT CROSS VALIDATION

Se temos n dados, então construímos n folds



Vantagens

- Quase imparcial (usa máximo de dados)
 - É determinístico, não sendo influenciado por sementes aleatórias
-

Desvantagens

- Alto custo computacional
- Resulta em alta variância
 - As scores são altamente correlacionadas, o que pode levar a estimativas instáveis do erro real de generalização

LEAVE-P-OUT CROSS VALIDATION

Uma combinação das duas estratégias anteriores

- Remove p amostras e treina com as restantes

Gera um número **extremamente grande** de combinações

$$\binom{n}{p} = c(n, p) = \frac{n!}{p!(n-p)!}$$



Se $n = 50$ e $p = 10$, temos que

$$c(50, 10) = \frac{50!}{10!(50-10)!} = \frac{50!}{10! \cdot 40!} = 10.272.278.170 \text{ combinações}$$

K-FOLD ESTRATIFICADO

Em classificação, divisões aleatórias podem criar *folds* onde uma classe está ausente ou sub-representada

- A **estratificação** garante que a proporção de classes em cada fold seja idêntica à do dataset original



O PROBLEMA DO AGRUPAMENTO

Em muitos cenários, as amostras não são independentes


- Médico: Várias imagens do mesmo paciente
- Usuário: Diversas sessões do mesmo cliente
- Geográfico: Várias medições na mesma fazenda

Se o modelo observa o mesmo grupo no treino e no teste, ele memoriza a identidade do grupo em vez de aprender padrões generalizáveis

K-FOLD AGRUPADO

Garante que o mesmo grupo nunca apareça simultaneamente no treino e no teste


- O objetivo é testar se o modelo consegue generalizar para **grupos inéditos**



K-FOLD AGRUPADO E ESTRATIFICADO

Combinação das estratégias de agrupamento e estratificação

- Melhor desempenho para dados complexos
- Tenta preservar a distribuição das classes em cada *fold*, mantendo cada grupo dentro de um único *fold*
- Muito útil quando os dados são desbalanceados



Treina em todos os grupos exceto um, que é usado para teste

- Repete para todos os grupos

De forma similar, também temos o *Leave-P-groups-out*

- Assim como o *leave-p-out*, pode gerar um número exponencial de combinações