

APRENDIZADO POR REFORÇO

EAB067 - Aprendizado de Máquina

Atualizado em: 26 de maio de 2026

Iago Carvalho

Departamento de Ciências da Computação

Programa de Pós-Graduação em
Estatística Aplicada e Biometria



DA PREVISÃO PARA A DECISÃO

Até agora, estudamos modelos que recebem exemplos rotulados e aprendem a prever uma saída

Supervisionado

Aprende uma função a partir de pares (x, y)


- Entrada: dados rotulados
- Saída: predição
- Avaliação: erro de previsão

Aprendizado por reforço

Aprende a agir por interação, tentativa, erro e recompensa

- Entrada: experiência no ambiente
- Saída: ação ou política
- Avaliação: retorno acumulado

Aprendizado por reforço estuda como um agente deve agir em um ambiente para maximizar uma recompensa acumulada



Essência

O agente não recebe a resposta correta para cada situação; ele aprende pelas consequências das ações.

O QUE PRECISAMOS SABER EM APRENDIZADO POR REFORÇO?

Antes dos algoritmos, precisamos dominar os conceitos que definem o problema

- | | |
|-------------------------|-----------------------|
| 1. Agente | 5. Recompensa |
| 2. Ambiente | 6. Política |
| 3. Estado ou observação | 7. Retorno e desconto |
| 4. Ação | 8. Função valor |

Ideia

Esses oito elementos descrevem quem decide, onde decide, o que pode fazer e como avaliamos suas decisões.

1. AGENTE E 2. AMBIENTE

O aprendizado por reforço começa com uma interação entre duas partes

Agente

Entidade que toma decisões e aprende com as consequências

- observa a situação atual
- escolhe ações
- recebe recompensas
- ajusta seu comportamento

Ambiente

Sistema com o qual o agente interage

- recebe ações
- muda de estado
- devolve observações
- fornece recompensas

3. ESTADO OU OBSERVAÇÃO E 4. AÇÃO

A cada passo, o agente precisa saber algo sobre a situação e escolher o que fazer

Estado ou observação

Informação disponível para tomar decisão

- Estado: descrição completa relevante
- Observação: sinal parcial ou ruidoso
- Ex.: tela do jogo, posição do robô, histórico do usuário

Ação

Escolha feita pelo agente

- Pode ser discreta ou contínua
- Define o que o agente consegue controlar
- Ex.: mover, recomendar, dosar, comprar

5. RECOMPENSA E 6. POLÍTICA

Recompensa diz o que foi bom; política diz como o agente decide

Recompensa

Sinal numérico recebido após uma ação

- mede consequência imediata
- guia o aprendizado
- deve representar o objetivo real

Política

Regra usada para escolher ações

- determinística: $a = \pi(s)$
- estocástica: $\pi(a | s)$
- é o comportamento que queremos melhorar

7. RETORNO E DESCONTO

O agente não busca apenas recompensa imediata, mas recompensa acumulada no tempo

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

- G_t é o retorno a partir do instante t
- $\gamma \in [0, 1]$ é o fator de desconto

γ próximo de 0

O agente age de forma mais imediatista

γ próximo de 1

O agente considera efeitos de longo prazo

8. FUNÇÃO VALOR

A função valor estima a utilidade esperada de estados ou ações

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid S_t = s]$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a]$$

- $V^{\pi}(s)$ mede quão bom é estar em um estado
- $Q^{\pi}(s, a)$ mede quão bom é escolher uma ação em um estado
- Esses conceitos sustentam algoritmos de aprendizado por reforço como o SARSA, Q-learning e o DQN

RL COMO PROBLEMA DE DECISÃO SEQUENCIAL

A decisão atual altera as situações que o agente encontrará depois


- O agente observa uma situação do ambiente
- Escolhe uma ação disponível naquela situação
- Recebe uma recompensa imediata
- Passa para uma nova situação
- O objetivo é escolher bem ao longo de toda a sequência

Consequência

Uma ação pode ser ruim no curto prazo e boa no longo prazo, ou o contrário.

FORMALIZAÇÃO EM TEMPO DISCRETO

A formulação mais comum escreve a interação em passos discretos:
 $t = 0, 1, 2, \dots$



$$s_t \rightarrow a_t \rightarrow r_{t+1}, s_{t+1} \rightarrow a_{t+1} \rightarrow r_{t+2}, s_{t+2} \rightarrow \dots$$

A discretização no tempo é uma escolha de modelagem

- O ambiente real pode evoluir continuamente
- O agente toma decisões em instantes separados
- Cada ação vale até a próxima decisão ou observação
- O intervalo entre decisões deve ser coerente com o problema

Exemplo

Um robô pode atualizar seus comandos a cada 0,1 segundo; um sistema de recomendação pode agir a cada visita do usuário.

No modelo ideal, o estado contém toda a informação necessária para decidir

Estado

Resumo da situação real do ambiente

- posição de um robô
- tabuleiro de um jogo
- condição de um paciente

Ação

Escolha disponível ao agente naquele instante

- mover, acelerar, frear
- recomendar um item
- aplicar uma intervenção

OBSERVABILIDADE

Em muitos problemas, o agente não enxerga o estado completo do ambiente

- **Totalmente observável:** a observação contém todo o estado relevante
- **Parcialmente observável:** o agente recebe apenas sinais incompletos ou ruidosos
- Histórico, sensores adicionais ou memória podem ajudar a reconstruir a situação
- A observabilidade afeta diretamente a dificuldade do aprendizado

Intuição

Dirigir com todos os sensores funcionando é diferente de decidir apenas com uma câmera ruim.

AÇÕES DISCRETAS E AÇÕES CONTÍNUAS

O conjunto de ações pode ser finito ou contínuo

Ações discretas

Escolha entre alternativas enumeráveis

- cima, baixo, esquerda, direita
- comprar, vender, manter
- tratamento A, B ou C

Ações contínuas

Escolha de valores reais

- torque de um motor
- ângulo de direção
- dose de medicamento

POLÍTICA: O COMPORTAMENTO DO AGENTE

A política define como o agente escolhe ações a partir do estado observado

- Pode ser uma regra fixa ou um modelo aprendido
- Pode escolher sempre uma ação específica ou sortear ações
- É o objeto central que queremos melhorar durante o treinamento
- A qualidade da política é medida pelo retorno que ela gera

Pergunta

Dado o estado atual s , qual ação o agente deve tomar?

POLÍTICA DETERMINÍSTICA

Uma política determinística associa cada estado a uma única ação

$$a = \pi(s)$$

- Se o agente volta ao mesmo estado, escolhe a mesma ação
- É fácil de interpretar e executar
- Pode ser adequada quando queremos comportamento previsível
- Pode explorar pouco se não houver algum mecanismo adicional de exploração

Exemplo

Em um mundo em grade: se estou nesta célula, sempre vou para a direita.

Uma política estocástica define uma distribuição de probabilidade sobre ações

$$\pi(a \mid s) = P(A_t = a \mid S_t = s)$$

- No mesmo estado, ações diferentes podem ser escolhidas em visitas diferentes
- A aleatoriedade pode ajudar na exploração
- É natural em métodos de gradiente de política, REINFORCE, Actor-Critic e PPO
- Permite representar incerteza ou variabilidade no comportamento do agente

A política gulosa escolhe sempre a ação com maior valor estimado

$$a_t = \arg \max_a Q(s_t, a)$$

- É simples e fácil de interpretar
- Usa apenas o conhecimento atual do agente
- Pode explorar pouco e ficar presa em estimativas iniciais ruins

Intuição

Sempre escolher a melhor alternativa conhecida até agora.

A política ϵ -gulosa mistura aproveitamento e exploração aleatória

$$a_t = \begin{cases} \arg \max_a Q(s_t, a), & \text{com probabilidade } 1 - \epsilon \\ \text{ação aleatória,} & \text{com probabilidade } \epsilon \end{cases}$$

- Se ϵ é alto, o agente explora mais
- Se ϵ é baixo, o agente aproveita mais
- Muitas aplicações reduzem ϵ ao longo do treinamento
- É muito usada com SARSA e Q-learning

A política softmax escolhe ações com probabilidades maiores para valores estimados maiores

$$\pi(a \mid s) = \frac{\exp(Q(s, a)/\tau)}{\sum_{a'} \exp(Q(s, a')/\tau)}$$

- Todas as ações podem ser escolhidas, mas ações melhores são mais prováveis
- τ é a temperatura da distribuição
- τ alto: probabilidades mais parecidas
- τ baixo: comportamento mais próximo da política gulosa

Uma política aleatória escolhe ações ao acaso, frequentemente com probabilidades iguais

$$\pi(a | s) = \frac{1}{|\mathcal{A}(s)|}$$

- É útil como ponto de comparação
- Ajuda a verificar se um algoritmo realmente aprendeu algo
- Pode ser usada no início para coletar experiências diversas
- Normalmente não é uma boa política final

UCB escolhe ações combinando valor estimado e incerteza

$$a_t = \arg \max_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

- $Q_t(a)$ representa a recompensa média estimada
- $N_t(a)$ é o número de vezes que a ação foi testada
- Ações pouco testadas recebem um bônus de exploração
- É muito comum em problemas de bandits

Thompson sampling escolhe ações amostrando crenças sobre qual ação é melhor

1. Manter uma distribuição de crença sobre o valor de cada ação
2. Amostrar um possível valor para cada ação
3. Escolher a ação com melhor valor amostrado
4. Atualizar as crenças após observar a recompensa

Intuição

Ações incertas ainda podem ser escolhidas, mas ações com evidência favorável tendem a dominar.

COMPARANDO POLÍTICAS COMUNS

Política	Tipo	Ideia	Uso comum
Determinística	fixa	$a = \pi(s)$	controle previsível
Estocástica	probabilística	$\pi(a s)$	exploração natural
Gulosa	determinística	melhor ação estimada	exploração baixa
ϵ -gulosa	mista	melhor ação ou sorteio	SARSA, Q-learning
Softmax	estocástica	probabilidade pelo valor	exploração suave
Aleatória	estocástica	ação ao acaso	baseline
UCB	determinística	valor + incerteza	bandits
Thompson	estocástica	amostra crenças	bandits

Função da política

Ela controla o equilíbrio entre usar o que já foi aprendido e buscar novas informações.

O caso clássico de RL é formalizado como um Processo de Decisão de Markov (MDP)

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

- $\mathcal{S}$: conjunto de estados
- $\mathcal{A}$: conjunto de ações disponíveis
- $P(s' \mid s, a)$: dinâmica ou probabilidade de transição
- $R(s, a, s')$: recompensa esperada na transição
- γ : fator de desconto

A hipótese de Markov diz que o estado atual resume o passado relevante

$$P(S_{t+1} \mid S_t, A_t, S_{t-1}, A_{t-1}, \dots) = P(S_{t+1} \mid S_t, A_t)$$

Interpretação

Se sabemos o estado atual e a ação escolhida, o histórico completo não acrescenta informação para prever o próximo estado.

OBJETIVO: POLÍTICA ÓTIMA

O objetivo é encontrar uma política que maximize o retorno esperado

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi}[G_t]$$

- A política ótima pode sacrificar recompensa imediata por ganhos futuros
- A qualidade de uma política é avaliada pelas trajetórias que ela gera
- Em geral, o agente precisa aprender essa política a partir de amostras

EXPLORAÇÃO E APROVEITAMENTO

O agente precisa equilibrar duas necessidades durante o aprendizado

Exploração

Testar ações pouco conhecidas para descobrir alternativas melhores

Aproveitamento

Usar a melhor ação conhecida até o momento

Tradeoff

Explorar demais reduz recompensa no curto prazo; explorar de menos pode impedir descobrir uma política melhor.

ARREPENDIMENTO

Em alguns problemas, avaliamos o quanto perdemos por não escolher sempre a melhor ação

$$\text{Regret}(T) = \text{retorno do melhor comportamento} \\ - \text{retorno obtido até } T$$

- O arrependimento quantifica o custo da exploração e dos erros
- Algoritmos bons aprendem de modo que o arrependimento cresça lentamente
- Esse conceito aparece com destaque em bandits e em análises teóricas de RL

Temos 3 desafios principais quando desenvolvemos algoritmos de aprendizado supervisionado

- **Amostras:** aprender a partir de experiências observadas no ambiente
- **Aproximação de função:** representar valores ou políticas quando há muitos estados
- **Planejamento:** usar um modelo do ambiente para simular consequências antes de agir

Visão geral

Muitos algoritmos diferem principalmente em como combinam experiência, estimativas de valor, políticas e modelos.

EXEMPLO: MUNDO EM GRADE

Um agente se move em uma grade tentando chegar ao objetivo

				1
			-1	
A				


ações: cima, baixo, esquerda, direita

Estados são posições; ações movem o agente; recompensas guiam o comportamento.

PROBLEMA DO BANDIDO MULTIARMADO

O bandido multiarmado é o caso mais simples de aprendizado por reforço: não há transições de estado

- Há um conjunto de ações, chamadas de braços ou alavancas
- Em cada rodada, o agente escolhe um braço
- O braço escolhido gera uma recompensa aleatória
- A distribuição de recompensas é desconhecida



BANDITS: FORMULAÇÃO

Em cada rodada t , o agente escolhe uma ação $A_t \in \{1, 2, \dots, k\}$ e observa apenas a recompensa daquela ação

$$R_t \sim P(\cdot \mid A_t)$$

- Cada braço tem um valor esperado desconhecido:
 $q_*(a) = \mathbb{E}[R_t \mid A_t = a]$
- O agente estima esses valores a partir das recompensas observadas
- Como só observa o braço escolhido, não sabe o que teria acontecido com os outros braços
- O problema central é aprender enquanto tenta acumular recompensa

BANDITS: EXPLORAÇÃO E APROVEITAMENTO

Bandits tornam explícito o dilema entre explorar e aproveitar

Explorar

Testar braços pouco escolhidos para melhorar as estimativas

- Pode revelar uma opção melhor
- Pode gerar recompensa baixa no curto prazo

Aproveitar

Escolher o braço com maior recompensa esperada estimada

- Ganha mais agora
- Pode ignorar opções promissoras

BANDITS: ARREPENDIMENTO

Uma forma comum de avaliar um algoritmo de bandits é medir o arrependimento acumulado

$$\text{Regret}(T) = Tq_*(a^*) - \sum_{t=1}^T \mathbb{E}[R_t]$$

- a^* é o melhor braço em média
- O primeiro termo é o que ganharíamos escolhendo sempre o melhor braço
- O segundo termo é o que o algoritmo obteve em média
- Bons algoritmos exploram o suficiente para reduzir o arrependimento no longo prazo

Existem várias formas de decidir qual braço escolher

- **ϵ -gulosa**: escolhe aleatoriamente com probabilidade ϵ
- **UCB**: favorece braços com boa média ou grande incerteza
- **Thompson sampling**: amostra crenças sobre os valores dos braços
- **Softmax**: escolhe ações com probabilidade maior para valores estimados maiores

Conexão com RL

Bandits são RL sem estado dinâmico; por isso são uma porta de entrada natural para entender exploração.

Baseados em modelo

Aprendem ou conhecem como o ambiente muda

- Usam $P(s' | s, a)$ e $R(s, a, s')$
- Permitem planejamento
- Podem ser eficientes se o modelo for bom

Livres de modelo

Aprendem diretamente pela experiência

- Não exigem conhecer transições
- São úteis em ambientes complexos
- Incluem Q-learning e policy gradients

Quando conhecemos o modelo do ambiente, podemos calcular políticas ótimas por programação dinâmica

- **Avaliação de política:** calcula V^π para uma política fixa
- **Melhoria de política:** escolhe ações melhores usando os valores estimados
- **Iteração de política:** alterna avaliação e melhoria
- **Iteração de valor:** atualiza diretamente em direção ao valor ótimo

Limitação

Exige conhecer a dinâmica do ambiente e pode ser inviável em espaços grandes.

Métodos Monte Carlo aprendem valores a partir de episódios completos

1. Executar uma política e gerar um episódio
2. Observar o retorno obtido em cada estado ou par estado-ação
3. Atualizar a estimativa pela média dos retornos observados

Característica

Não precisam conhecer o modelo do ambiente, mas esperam o episódio terminar para atualizar.

QUANDO USAR APRENDIZADO POR REFORÇO?

RL é indicado quando o problema é naturalmente sequencial e envolve decisões com efeitos futuros

- Há um agente que pode interagir com um ambiente
- Existe uma recompensa mensurável
- Decisões atuais afetam oportunidades futuras
- Simulação ou coleta de interação é possível
- Métodos supervisionados simples não capturam bem a dinâmica da decisão